

## 机器学习

2018-1-22

金融工程 | 专题报告

# 机器学习白皮书系列之三：深度学习的方法介绍及金融领域应用实例

## 报告要点

### ■ 深度学习介绍及应用案例

本篇报告将焦点放在深度学习上，介绍了深度学习的常用算法和在金融领域上可以运用的场景，并给出了两个具体的案例。

### ■ 监督类方法介绍

监督的深度学习算法基于神经网络结构，这种系统一般由多个层堆叠组成特定神经网络，不同算法的差别来自层的组成结构及层与层之间的关系。深度神经网络在普通神经网络的基础上，增加隐含层的数量，学习输入与输出之间的非线性关系。循环神经网络随数据的输入生成动态模型，以捕捉之前的输出和当前输出的关系，并衍生出了如 LSTM 的结构，解决遗忘较长时间信息的问题。卷积神经网络主要通过卷积和池化的方式连接每层的输入和输出，达到降低数据维数，捕捉主要信息的目的。

### ■ 无监督类方法介绍

限制波尔兹曼机是一种既可以做监督学习也可以做无监督学习的网络结构。区别于一般的深度学习网络，限制波尔兹曼机仅由输入层和隐含层两层组成，隐含层可以是多个。限制波尔兹曼机可以实现数据的重构，得到输入数据的分布，在特征提取和数据降维方面有很好的效果。

### ■ 强化学习介绍

强化学习是一种介于监督学习和无监督学习之间的方法，以一种稀疏且具有延时的标签，探索环境到行为的最大奖励化的映射关系。强化学习可以真正实现摆脱数据的指导，根据每次行动得到的反馈找到最优策略。本文介绍了强化学习中最常使用的 Q 学习算法。

### ■ 深度学习与传统机器学习的比较

通过模型效率、结构、泛化能力及适用场景等维度比较深度学习和传统机器学习。目前在金融领域中深度学习的实践应用有限，积累的数据量并未能够利用深度学习在处理大数据上的优势，在自动提取特征上也不及人为的金融分析逻辑，且模型复杂度的增加会伴随着计算量的增大，与传统机器学习相比，在某些场景上更容易出现过拟合，因此更多是通过间接的方式例如利用其在搜集大数据上的优势获取新的数据源来辅助投资。

分析师 覃川桃

☎ (8621) 61118766

✉ qinct@cjsc.com.cn

执业证书编号：S0490513030001

联系人 陈洁敏

☎ (8621) 61118706

✉ chenjm5@cjsc.com.cn

## 相关研究

《红利策略：展望 2018》2018-1-14

《鹏华基金指数型产品的投资价值分析》  
2018-1-2

《2018，守株待兔》2018-1-1

**风险提示：**

1. 模型在使用中存在建模风险；
2. 本文所有测算均是基于历史数据并不代表未来收益。

## 目录

深度学习方法概述 .....	4
深度学习的成功案例 .....	4
深度学习在金融的应用 .....	5
为什么要用深度学习 .....	5
监督类方法介绍 .....	7
深度神经网络 .....	11
深度神经网络介绍 .....	11
深度神经网络在选股上的应用 .....	12
循环神经网络 .....	15
循环神经网络介绍 .....	15
循环神经网络在选股上的应用 .....	17
选股效果的评价 .....	19
卷积神经网络介绍 .....	19
无监督类方法介绍 .....	21
强化学习介绍 .....	23
强化学习与 Q 学习算法介绍 .....	23
强化学习在金融上的应用场景 .....	24
总结 .....	25

## 图表目录

图 1: 深度学习方法介绍 .....	4
图 2: AIEQ 与美国主要指数的表现比较 .....	5
图 3: 深度学习特征层级 .....	6
图 4: 深度学习和传统机器学习模型随数据量增加的表现 .....	6
图 5: sigmoid 函数曲线图 .....	8
图 6: tanh 函数曲线图 .....	9
图 7: ReLU\Leaky ReLU\softplus 函数曲线图 .....	10
图 8: 神经网络单个节点运算流程 .....	10
图 9: 深度神经网络结构图 .....	12
图 10: 高阶 sigmoid 激活函数曲线 .....	12
图 11: 深度神经网络多因子选股分档效果 .....	14
图 12: 循环神经网络随时间展开的结构图 .....	15
图 13: LSTM 结构图 .....	16

图 14: LSTM 隐含层运算流程图 .....	16
图 15: LSTM 多因子选股效果 .....	18
图 16: 限制波尔兹曼机正向传播过程 .....	20
图 17: 矩阵卷积过程 .....	20
图 18: 矩阵池化过程 .....	21
图 19: 卷积神经网络结构图 .....	21
图 20: 限制波尔兹曼机正向传播过程 .....	22
图 21: 限制波尔兹曼机反向传播过程 .....	22
图 22: 强化学习流程图 .....	23
图 23: 多种深度学习方法结合的选股流程 .....	26
表 1: 深度学习的应用 .....	4
表 2: 传统机器学习和深度学习比较 .....	7
表 3: 其他用来描述神经网络特征的指标 .....	11
表 4: 使用的因子数据及其描述 .....	13
表 5: 深度神经网络多因子选股的分年表现 .....	14
表 6: 深度神经网络多因子选股的分组表现 .....	15
表 7: LSTM 模型多因子选股的分年表现 .....	18
表 8: LSTM 模型多因子选股的分组表现 .....	19
表 9: 传统机器学习和深度学习比较 .....	25

## 深度学习方法概述

本篇将继续之前机器学习及其在金融领域应用的探讨，将焦点放在深度学习算法上。深度学习可以解决监督学习、非监督学习和强化学习任务，同时可以处理除结构性数据之外的非结构性数据和时间序列数据。

图 1：深度学习方法介绍



资料来源：长江证券研究所

机器学习作为人工智能的核心，其传统算法在解决很多问题上都表现出了高效性。随着近些年数据处理技术上的进步和计算能力的提升，深度学习得以在很多问题上也大放光彩，成为近一段时间互联网、金融等领域的大热门。深度学习可以解决传统机器学习研究的问题，从监督学习、非监督学习到强化学习，适用范围广泛，同时区别于传统机器学习在处理数据上的局限性，深度学习可以应用于除了结构性数据之外的非结构性数据和时间序列数据，尤其在非结构性数据上有着优异表现。在量化领域，深度学习可以在模型精确性上对传统数学模型进行改良，在应用场景和研究角度上对传统量化方法进行补充，此外强化学习也可以为自动化交易的有效性提供保障。

## 深度学习的成功案例

目前在很多领域，深度学习都取得了突出的成就：

表 1：深度学习的应用

应用领域	成功案例	主要用到的深度学习方法
图像识别	微软识花，Facebook 人脸识别	卷积神经网络
语音识别	讯飞听见，Siri，小娜	循环神经网络
文本翻译	Google 翻译	循环神经网络
智能机器人	AlphaGo，Tesla 自动驾驶	强化学习

资料来源：长江证券研究所

近期，自动驾驶公交在深圳首发试运行，虽然这次的试验严格意义上来说并不是真正的“自动驾驶”，其本质的运行逻辑是第一个车辆“带领”后面的车辆，并通过通信低延迟和远程控制，实现一个车队后面的车辆的自动行驶。但是随着深度学习在自动驾驶领域的不断发展，真正意义上的自动驾驶仍然充满了前景。

## 深度学习在金融的应用


目前在金融领域较为成熟的深度学习应用一般都是基于其他领域上的成果，如利用语音识别向办理金融业务的用户提供自动服务，以及基于大数据分析的智能投顾。以智能投顾为例，通过对用户历史交易投资信息的分析，可以为用户提供自动化的证券投资组合管理服务。目前美国智能投顾公司如 Wealthfront 和 Betterment 在资产管理规模上迅速崛起，展示了智能投顾领域的巨大潜力和前景。

在量化投资领域，机器学习尤其是由统计学延伸的各种算法一直以来都被尝试应用在选股、择时等策略的开发上，随着深度学习在其他领域上的突破，其在自动化交易甚至投资策略的自开发自学习方面的应用成为了大家探索的焦点，全球最大的资产管理公司 BlackRock 更是专门成立了人工智能量化部门 SAE，试图向投资者提供科学量化的投资方式。

近期，由旧金山 EquBot 公司推出的首只人工智能 ETF—AI Powered Equity ETF (AIEQ) 于 2017 年 10 月 18 日在美国上市交易，该公司是 IBM 全球创业者计划的一部分，并与 ETF Managers Group 合作，利用 IBM Watson 超级计算机进行大数据处理，分析美国境内投资机会，对股票投资进行主动管理。

自推出后，AIEQ 的业绩表现备受关注。截至目前其表现效果不尽如人意，主要是在推出的前期一路下跌，近期表现好转，但是其最终业绩仍待时间的证明。

图 2：AIEQ 与美国主要指数的表现比较



资料来源：Wind，长江证券研究所


## 为什么要用深度学习

深度学习目前最成功的场景应用是在模式识别上，即利用已知数据，对具有一定空间、时间分布信息的数据与类别标号之间的映射做一个较好的估计。之所以在结构性识别的任务中，深度学习可以表现得比传统机器学习算法更好，主要有以下三点原因：

1. 深度学习的自动提取特征比传统机器学习的人为提取特征过程更加高效。传统机器学习一般通过人为提取特征，训练模型对目标进行预测，这种方式效率低，且一般不具有普适性，即针对当前任务有效，而类似场景并不十分有效。深度学习通过多层级的信息挖掘，层层递进的获取输入数据的特征，给出目标的预测。在

特定的应用场景中，深度学习借鉴了人类神经元工作的原理，构建神经网络，如图像识别中的卷积神经网络和语音识别中的循环神经网络，当任务改变时，只需要微调结构，如神经元的激活函数，就可以得到较好的效果。这里以图像识别和文本识别为例，展现多层级的特征提取过程：


图 3：深度学习特征层级



资料来源：长江证券研究所

2. 深度学习可以通过复杂的结构和多重非线性处理层更好的捕捉各类非线性关系；
3. 深度学习随着数据量的增加模型效果会不断的改善，而传统机器学习在面临庞大数据集时处理的效率和效果都有较大局限性，这也是当前深度学习有逐渐取代传统机器学习模型趋势的最大原因。

图 4：深度学习和传统机器学习模型随数据量增加的表现



资料来源：长江证券研究所

但是就目前的经验来看深度学习在金融领域中实践应用有限，且与传统的机器学习算法相比，并没有显示出巨大的优势，其在金融应用的局限性主要有以下几点原因：

1. 目前量化策略大多基于金融分析的逻辑，且这方面有很多逻辑已经相对完善，如多因子选股，深度学习的自动提取特征过程并没有来得比人为已经提取的特征表现更好；
2. 金融领域数据量的积累不多，并未能够利用到深度学习处理大数据时的优势，反而会因为数据量少容易产生样本内的过拟合导致模型的泛化能力差。此时传统机器学习的表现反而优于深度学习模型。不过出于这个考虑，之后我们看到的有效的深度学习实践案例很有可能会率先出现在日内或高频交易，而非低频交易。
3. 总结目前深度学习应用得较为成功的情景，如图像识别、音频识别甚至到人机对战，其共同特点是应用边际明确、规则清晰、环境稳定、训练样本集庞大，即输



入数据和输出数据的分布以及其映射法则是不变的，而金融市场人为因素多，市场往往瞬息万变，信噪比低，深度学习目前不能很好的应对这种情况。

在一些大数据竞赛（如 Kaggle）中的获奖作品可以观察到 XGBoost 和随机森林是目前分析结构化数据最好用的工具，深度学习的使用也仅限于图像或文字的分析。深度学习仍然需要大量的数据进行培训，对小样本的培训（通过所谓的生成对抗模型）仍处于初步研究阶段。

传统机器学习算法和深度学习比较总结如下表：

表 2：传统机器学习和深度学习比较

类型	传统机器学习算法	深度学习算法	金融领域情况	优劣比较
数据结构	适用于结构性数据	适用于结构性数据、非结构性数据和时序数据	目前多以结构性数据和时序数据呈现	结构性数据传统机器学习模型探索更多，时序数据可以采用深度学习模型
特征提取	人工提取	模型自动提取	目前多以金融分析逻辑人工提取特征	模型目前难以实现有效的特征自动提取；传统机器学习更优
数据级别	一般不处理大数据级别	可处理大数据级别	目前非大数据级别	并无明显优劣
计算效率	一般	结构越复杂计算量越大	目前大多数策略不需要很高计算效率	当深度学习算法结构较为复杂时，传统机器学习更优
模型泛化能力	在样本内可以较好进行非线性拟合，泛化能力较强	大数据情况下优于传统机器学习模型；样本内可以达到完美拟合，数据量不大时泛化能力差	目前非大数据级别	传统机器学习更优
模型偏差	一般，超参数的存在可以降低偏差	错误的结构会造成较大偏差	金融市场变化较大	传统机器学习更优

资料来源：长江证券研究所

## 监督类方法介绍

本章节将重点介绍深度学习中最常用到的网络结构，并给出在适当场景中应用的例子。

监督类的深度学习算法大多基于神经网络结构，其也是深度学习中最基础和最重要的结构之一。神经网络结构的最小单位是神经元（也可被称为单个节点），在生物学上神经元也是构成大脑神经系统结构和功能的基本单位。深度学习中神经元可以被看作是一个简单的计算器，计算给定输入的加权平均值，如果该值超过预定阈值则输出结果。一个神经网络系统一般是由多层堆叠的神经元组成，不同算法的差别来自层的组成结构及层与层之间的关系。每层中的神经元将输入数据与一组系数（或称权重）结合，通过放大或抑制输入来指定其在算法学习任务中的重要性。输入数据与权重的乘积之和将进入下一个处理单元，神经元内部通过激活函数的处理，判定信号是否继续在网络中传递，以及传递的距离，从而决定信号如何影响网络的最终结果，例如分类动作。

激活函数通常有以下五点性质：

1. **非线性**：当激活函数是非线性的时候，一个两层的神经网络就可以逼近基本上所有的函数，但是如果函数是线性的，就不满足这个性质，尤其在多层网络结构中，使用线性函数和单层神经网络是等价的。


2. **可微性**：函数的可微保证了训练模型时梯度下降法可以找到最优解。
3. **单调性**：当激活函数是单调的时候，单层网络能够保证是凸函数。
4.  $f(x) \approx x$ ：函数近似等于  $x$  可以在随机初始化参数时保证神经网络训练的高效。
5. 输出值的范围：当激活函数的输出值是有限的时候，基于梯度下降的优化方法会更加稳定，当输出值是无限的时候，往往需要更小的学习率保证训练效果。

常用的激活函数有 sigmoid、tanh 和 ReLU。

sigmoid 函数是最早的常用激活函数，这一函数也是逻辑回归的基础，它可以把任何输入都映射到 0 和 1 之间，数学公式和函数曲线如下：

$$f(x) = \frac{1}{(1 + e^{-x})}$$

图 5: sigmoid 函数曲线图



资料来源：长江证券研究所

sigmoid 函数在以前使用得非常多，现在却逐渐被摒弃，主要有以下两个原因：


1. 梯度消失问题。当输出值在 0 和 1 附近的时候，函数的梯度几乎为 0，使得在反向传播训练模型的过程中，权重和偏差参数无法被更新，导致神经网络无法继续被优化；
2. 函数的输出值始终大于 0，假设后面的输入都是非 0 的信号，在反向传播的过程中权重会均往正方向或负方向更新，并非是最优的梯度下降路径。

tanh 函数解决了 sigmoid 的第二个问题，函数关于原点中心对称，其本质是一个放大的 sigmoid 函数，其函数公式和函数曲线如下：

$$f(x) = \frac{2}{(1 + e^{-2x})} - 1$$



图 6: tanh 函数曲线图



资料来源：长江证券研究所

近年来最为流行的激活函数是 ReLU，相比于 sigmoid 和 tanh 函数，ReLU 在随机梯度下降时的收敛速度更快，其函数表达式如下：

$$f(x) = \max(0, x)$$

ReLU 的缺点在于在训练过程中可能会出现大量“坏死”的神经元，即这些神经元的输入不会被激活到下一步的输入中去，主要原因在于 ReLU 函数在  $x$  小于 0 的时候梯度被置为零。改进的 Leaky ReLU 函数通过在  $x$  小于 0 的时候赋予一个很小的梯度值，如 0.05，解决这个问题，其函数表达式如下：


$$f(x) = \begin{cases} x & x \geq 0 \\ 0.05x & \text{else} \end{cases}$$

除此之外，softplus 作为 ReLU 函数的平滑，也可以很好的解决上述问题，其函数表达式如下：

$$y = \log(1 + e^x)$$

三个函数的函数曲线如下图所示：

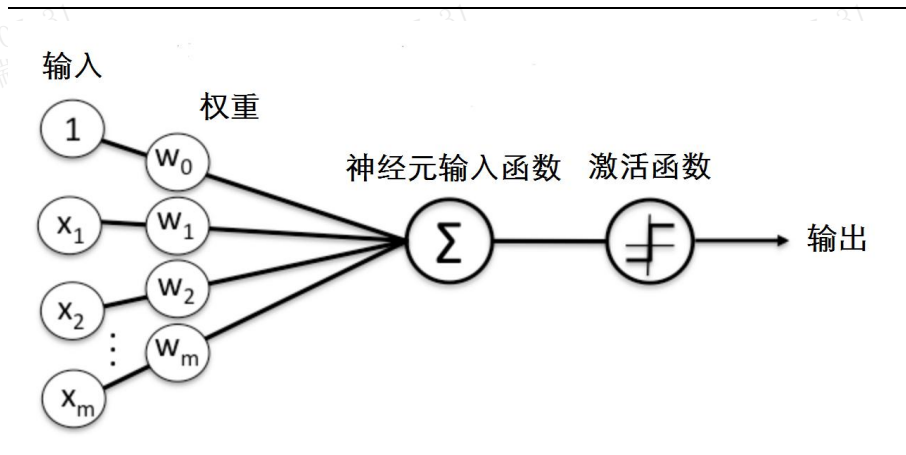
图 7：ReLU\Leaky ReLU\softplus 函数曲线图



资料来源：长江证券研究所

在经过激活函数处理之后，结合给定的调整值就得到了当前节点上的输出，以下是在单个节点上运算的示意图：


图 8：神经网络单个节点运算流程



资料来源：长江证券研究所

多层神经网络的首个设计是多层感知器（MLP），其设计方式使得输入信号仅通过网络中的每个节点一次（也称为“前馈”神经网络）。MLP 具备典型的神经网络结构，由三层组成，分别是输入层、隐含层和输出层，数据输入至输出层，经过隐含层的处理，由输出层给出结果，如分类的类别。每一层是一个节点层，由一系列节点构成，层与层的节点一般以全连接的方式连接，而每一层内的神经元一般不连接。结构图如下：

图 9：典型的神经网络结构图



资料来源：长江证券研究所

除了上述所提到的层数和神经元个数，其他用于描述神经网络特征的指标如下：

表 3：其他用来描述神经网络特征的指标

神经网络特征	在网络结构设计和表现中的作用	常见应用
损失函数	用于衡量输出结果和真实结果的差异	MSE（回归）、二元交叉熵（分类）
优化器	基于误差的网络结构权值调整	随机梯度下降
初始化方案	初始化网络结构权值	Xavier 初始化
激活函数	提供线性组合的非线性效应	ReLU（用于中间层）、线性（用于回归的输出层）、Sigmoid（用于分类的输出层）
正则化方法	用于惩罚较大权值以防过度拟合	丢弃 dropout

资料来源：J.P.Morgan，长江证券研究所

由上述各项可以构建出完整的神经网络结构，并且根据数据特点和应用目的，衍生出各种不同算法。下面介绍基于神经网络结构的三种代表性算法。

## 深度神经网络

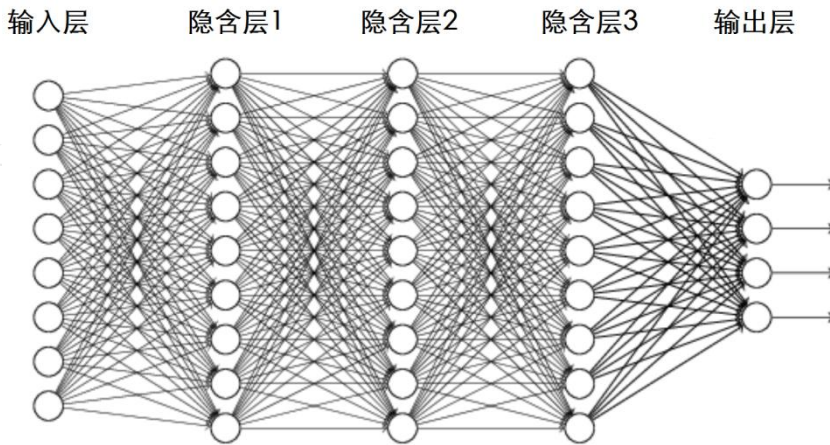
### 深度神经网络介绍

深度学习网络（Deep Neural Network，简称 DNN）的定义并不是很严格，三层以上（包括输入和输出层在内）的系统就可以称为“深度”学习。传统机器学习系统也可看做是由一个输入层和一个输出层组成的浅层网络。

在深度学习网络中，每一个节点层在前一层输出的基础上学习识别一组特定的特征。随着神经网络深度增加，节点所能识别的特征也就越来越复杂，因为每一层会整合并重组前一层特征。这种结构让深度学习网络能处理大规模高维度数据集，进行数十亿个参数的非线性函数运算，发现未标记、非结构化数据中的潜在结构，而现实世界中的数据关系绝大多数都属于这一类型。一般来说网络训练所用的数据越多，网络所包含的隐含层越多，模型的准确度就越高。

一个最简单的通用的深度神经网络结构就是在隐含层中不断加入全连接层，目的在于通过层数的增加学习非线性的关系，网络结构如下图所示：


图 10：深度神经网络结构图



资料来源：长江证券研究所

在深度神经网络中，梯度下降法常常会遇到梯度消失和膨胀的问题，意味着相较于浅层次神经网络结构深度学习网络需要更大的计算量和精确的计算。以常用的 sigmoid 函数为例，随着层数的增加，数据的曲线随输入变化如图：

图 11：高阶 sigmoid 激活函数曲线



资料来源：长江证券研究所

总的来说，深度神经网络比最简单的神经网络计算上要求更高，模型也更加精确。

## 深度神经网络在选股上的应用

深度神经网络可以通过多个隐含层学习到输入和输出之间的非线性关系，用来做监督学习中的分类和回归。这里以分类任务为例，将深度神经网络应用在多因子选股中。在保留传统的多因子选股的分析框架下，通过实际效果来评判深度神经网络使用的性价比。

策略的构建过程如下：

- 样本区间：2005-01-31 到 2017-12-31；

- 回测区间：2011-01-31 到 2017-12-31；
- 股票池为全部 A 股，剔除上市未满一年的股票，剔除 ST 股票，剔除最近一个月停牌时间超过 10 个交易日的股票，剔除每个截面期下一个交易日停牌的股票；
- 每年进行滚动更新模型，月度进行调仓；
- 训练集为过去 6 年的数据，每个月下期的涨跌情况为标签，选取 17 个因子，训练模型，作为下个月涨跌情况的预测；
- 神经网络结构的特征：由二个隐含层组成，分别包含 32 个和 8 个神经元，并以 ReLU 作为激活函数，每层的传递随机丢弃 20% 的数据以防止模型过拟合。输出层使用 sigmoid 函数，损失函数使用信息熵。

因子及其描述如下表所示：


表 4：使用的因子数据及其描述

大类因子	具体因子	因子描述
价值	EP	净利润(TTM)/总市值
	BP	净资产/总市值
成长	Sale_G_Q	营业收入季度同比增速
	ROE_G_Q	ROE 季度同比增值
	ROE_TTM	ROE(TTM)
盈利质量	Grossprofitmargin_TTM	毛利率(TTM)
	Assetturnover_TTM	资产周转率(TTM)
动量	Momentum	过去 1 年涨跌幅减去过去一个月涨跌幅
市值	Ln_size	流通市值对数
反转	Return_1m	过去 1 个月涨跌幅
波动率	Std_Res_1m	过去 1 个月的残差波动率
	Std_1m	过去 1 个月的个股波动率
Beta	Beta	CAPM 模型中的 Beta
流动性	Turn_1m	过去 1 个月的个股换手率
	Turn_63d	过去 63 个交易日个股换手率
	Turn_252d	过去 252 个交易日个股换手率
行业因素	Ind_Ret	所在中信一级行业过去一个月涨跌幅

资料来源：长江证券研究所

将预测的下期涨跌情况分为 10 组，从第一组到第十组的单调性明显，以等权指数作为比较基准，第一组相对于基准有较高超额收益。

图 12：深度神经网络多因子选股分档效果



资料来源：Wind，长江证券研究所

分年收益表现如下：

表 5：深度神经网络多因子选股的分年表现

年份	收益率	超额收益率	夏普比率	最大回撤	相对最大回撤
2011	-17.04%	15.58%	-0.66	28.50%	1.71%
2012	28.11%	22.56%	1.14	18.41%	5.51%
2013	30.48%	2.87%	1.36	17.09%	4.93%
2014	47.07%	-0.16%	2.05	10.05%	7.75%
2015	162.36%	40.19%	2.20	42.32%	3.65%
2016	18.49%	26.29%	0.71	19.43%	2.65%
2017	-9.97%	3.99%	-0.69	15.98%	3.14%

资料来源：天软科技，长江证券研究所

从 2011 年回测至今，深度神经网络的选股策略基本上每年均可以获得正的超额收益率，相对于基准的回撤也能够控制在一定的范围内。



分组来看，每一组的收益特征如下：

表 6：深度神经网络多因子选股的分组表现

组别	年化收益率	超额收益率	夏普比率	最大回撤	月盈亏比	信息比率	Calmar比率
第一组	68.12%	23.57%	1.04	42.32%	1.44	0.15	1.61
第二组	41.26%	11.35%	0.83	50.83%	1.64	0.13	0.81
第三组	30.67%	6.67%	0.72	52.10%	1.47	0.09	0.59
第四组	16.79%	0.08%	0.53	53.97%	1.02	0.00	0.31
第五组	14.65%	-0.95%	0.50	52.70%	0.88	-0.02	0.28
第六组	9.51%	-3.32%	0.40	52.68%	0.54	-0.07	0.18
第七组	4.87%	-5.42%	0.29	53.48%	0.77	-0.13	0.09
第八组	0.15%	-7.62%	0.16	59.00%	0.59	-0.18	0.00
第九组	-4.36%	-9.85%	-0.02	62.27%	0.66	-0.21	-0.07
第十组	-8.35%	-11.76%	-0.23	75.27%	1.10	-0.20	-0.11

资料来源：天软科技，长江证券研究所

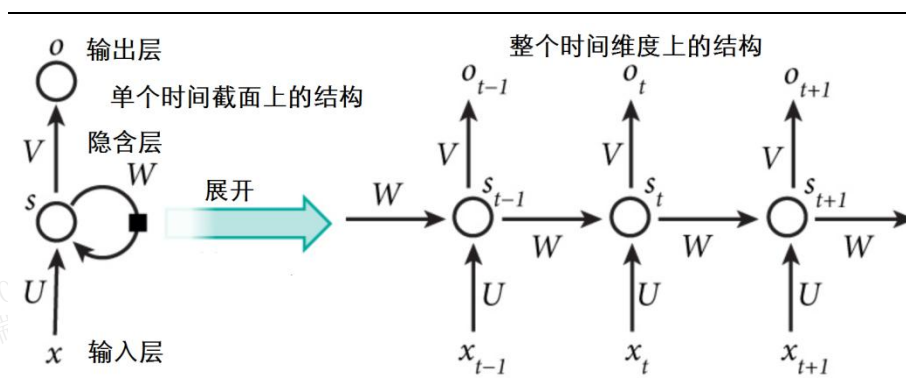
## 循环神经网络

### 循环神经网络介绍

#### 循环神经网络结构

传统的神经网络是基于所有时刻的输入和输出间相互独立的假设来生成已学习数据的静态模型，并根据新接受的数据进行运算。但在很多情景中，如语音识别中预测当前的单词的含义，需要知道之前的输出结合上文语境做出判断，循环神经网络（Recurrent Neural Networks，简称 RNN）可以用于解决这类问题。循环神经网络也被称为递归神经网络是受到人类对于近期事件会有所保留的背景而启发，循环神经网络会随着数据的输入生成动态模型。下图显示了一个循环神经网络展开成一个完整网络的示意图：

图 13：循环神经网络随时间展开的结构图



资料来源：长江证券研究所

在每一个时间截面上，循环神经网络的计算如下：

1. 输入层： $x_t$  是  $t$  时刻的输入，通过权重  $U$  的分配输入到隐含层。
2. 隐含层： $s_t$  是时间步骤的隐藏状态  $t$ ，即是网络的“记忆”，根据前一个隐藏状态和当前输入的计算， $s_t = f(Ux_t + Ws_{t-1})$ ， $U$  和  $W$  分别对应当前输入和前一个时刻隐藏状态的权重，函数  $f$  为通常意义上的激活函数，如  $\tanh$  或  $\text{ReLU}$ 。


3. 输出层： $o_t$ 是  $t$  时刻的输出，由隐藏状态的输出值通过权重  $V$  的分配得到。

需要特别指出的是循环神经网络中每一个时间截面的网络结构，权重是共享的。

### 长短记忆结构和门控循环结构

计量经济学家通过 ARIMA 模型来进行时间序列预测，在样本量较小时取得的效果较好，可以适应时间序列的记忆效应，如持续性，平均回归，季节性等。在深度学习中，类似的模型是长短记忆网络结构（Long Short Term Memory，简称 LSTM）。一般 RNN 模型会对近期的事件给予更高权重，而会忽略距离较远的事件。但是有些时候例如在金融市场中当前的牛市趋势不仅依赖当前的市场情况，还可能会呈现和之前牛市类似的走势。LSTM 针对这一问题，改进了 RNN 的隐含层结构。

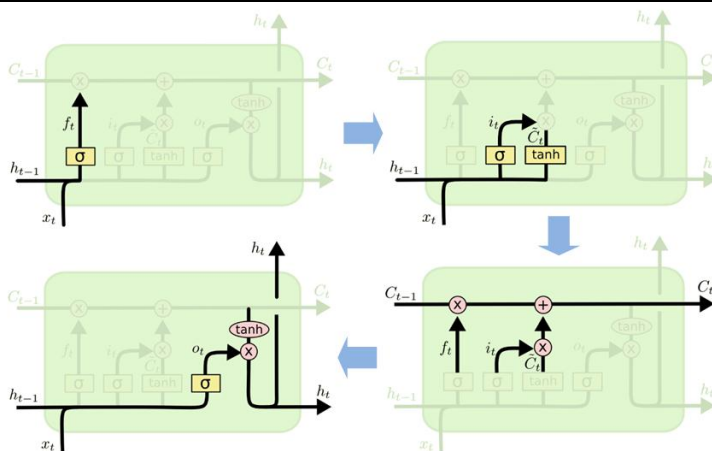
图 14：LSTM 结构图



资料来源：长江证券研究所

LSTM 的整体结构和 RNN 一样，区别在于隐含层的具体实现，LSTM 在其中加入了一个记录当前状态的单元，这个单元的值由上一个时刻的状态和当前的输入共同决定，以此来记录之前历史时刻的信息，隐含层在每一个时间截面上运算的具体流程见下图。

图 15：LSTM 隐含层运算流程图



资料来源：长江证券研究所

具体展开，分以下四个步骤：

1. 过去信息的记录：由当前的输入和前一个时刻的输出，决定当前的记忆单元需要

请阅读最后评级说明和重要声明

保存过去多少信息：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

激活函数 $\sigma$ 往往为 sigmoid 函数，将 $f_t$ 映射到 0 和 1 之间的数，1 表示过去的信息全部记录，0 表示过去的信息全部舍弃。

2. 当前信息的记录：由当前的输入和前一个时刻的输出，决定在状态单元中储存哪些新的信息，包含两个部分，一是当前的记忆单元需要保存当前多少信息，二是当前信息的表示：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

激活函数 $\sigma$ 往往为 sigmoid 函数，将 $i_t$ 映射到 0 和 1 之间的数，1 表示当前的信息全部记录，0 表示当前的信息全部舍弃。 $\tilde{C}_t$ 为当前信息的表示，作为当前状态的候选，通过激活函数  $\tanh$  映射得到。

3. 当前状态：由当前的信息和过去的信息，得到当前状态：

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

这一步通过两个权重 $f_t$ 和 $i_t$ ，来决定之前信息和当前信息各保留多少，若 $f_t$ 较大，则之后的模型会用到更多更远时间的信息，若 $i_t$ 较大，则之后的模型会用到更多更近时间的信息，以此避免了普通 RNN 网络结构中对较远时间点信息的遗忘。

4. 输出结果：由上一时刻的输出、当前时刻的输入和当前状态，得到当前输出：

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh(C_t)$$

## 循环神经网络在选股上的应用


循环神经网络可以记忆之前的信息，建立类似时间序列的模型，解决监督学习中分类和回归的任务。相对于深度神经网络来说理论上更适应于金融分析的应用场景。在此，仍然以上面的多因子选股为例来比较仅在改变模型而不调整因子数据基础上来单纯评判模型的效果。

策略的构建过程的其他部分与深度神经网络一致，网络结构设计如下：

- 网络结构的特征：模型由两个 LSTM 隐含层组成，分别输出到 32、8 个神经元，每层的传递随机丢弃 20% 的数据防止模型过拟合。并最后通过全连接层连接到输出层，以常用的 sigmoid 函数和信息熵作为损失函数，训练模型。

净值收益结果如下：

图 16：LSTM 多因子选股效果



资料来源：天软科技，长江证券研究所

从分组效果来看，也能够较好的区分每组收益，但是整体效果低于预期，弱于同等条件下的深度神经网络效果。

分年收益表现如下：

表 7：LSTM 模型多因子选股的分年表现

年份	收益率	超额收益率	夏普比率	最大回撤	相对最大回撤
2011	-22.60%	33.15%	2.61	1.52%	22.41%
2012	28.73%	12.68%	3.61	2.09%	22.16%
2013	39.31%	16.43%	2.33	2.05%	10.12%
2014	66.69%	7.48%	2.12	3.77%	43.48%
2015	84.82%	48.81%	-0.29	9.51%	19.38%
2016	1.36%	22.60%	1.44	3.42%	5.11%
2017	-13.30%	19.51%	-0.27	4.52%	20.44%

资料来源：天软科技，长江证券研究所

分组来看，每一组的收益特征如下：

表 8：LSTM 模型多因子选股的分组表现

组别	年化收益率	超额收益率	夏普比率	最大回撤	月盈亏比	信息比率	Calmar比率
第一组	41.75%	10.03%	0.87	48.81%	1.65	0.09	0.86
第二组	24.82%	2.76%	0.67	47.65%	1.24	0.04	0.52
第三组	22.02%	1.65%	0.62	49.06%	1.54	0.03	0.45
第四组	16.59%	-0.73%	0.54	49.98%	1.27	-0.01	0.33
第五组	16.50%	-0.60%	0.53	51.66%	1.06	-0.01	0.32
第六组	17.12%	-0.19%	0.54	52.15%	1.13	0.00	0.33
第七组	10.60%	-3.11%	0.42	52.20%	1.13	-0.06	0.20
第八组	2.84%	-6.58%	0.24	55.17%	0.63	-0.13	0.05
第九组	-1.68%	-8.62%	0.11	60.57%	0.46	-0.15	-0.03
第十组	-5.28%	-10.21%	-0.02	62.68%	0.71	-0.13	-0.08

资料来源：天软科技，长江证券研究所

## 选股效果的评价

在保持原有的指标和分析框架下更容易比较单纯由深度学习模型带来的提升效果，但是无论是使用 DNN 还是使用 LSTM 模型，多头选股整体效果提升幅度不大。

这种比较也引起了一些思考：

- 1、深度学习在目前选股框架下是否无用武之地？DNN 训练时间包括参数优化及特征选取为 1 个小时左右；LSTM 模型训练时间为 3 小时；在处理目前中低频数据上效率和效果优势不明显，性价比比较低。
- 2、LSTM 模型的记忆是记忆有效信息还是记忆噪音？从 DNN 和 LSTM 两个模型的比较上来看，增加了记忆功能的 LSTM 表现反而不尽如人意，说明很多时候记忆的可能是干扰信息。这也引发了深度学习模型如何能真正实现所谓“自学习”将市场状态与有效指标结合的探索。
- 3、深度学习应用于国内金融市场的局限性？一个共识是在数据量以及数据质量上国内金融市场上的积累尚不足；高频数据一定程度上可以解决这个问题，不过需要思考的是在模型本身是否需要个性化？熟悉各类算法，然后设计更为合适的结构和分析框架是否是深度学习成功的必要的条件？这个决定了应用深度学习的门槛和能力边际。

## 卷积神经网络

### 卷积神经网络介绍

卷积神经网络 (Convolutional Neural Network, 简称 CNN) 通过局部扫描的过程，逐步一一制成图谱，调整这些图谱的比例，构建可扩缩且稳健的特征，目前在图像识别领域有着非常优异的表现。

与传统神经网络相比，卷积神经网络在处理层与层的连接上，有两点不同：


1. 在传统神经网络中，我们将每个输入神经元连接到下一层的每个输出神经元，即

全连接的连接每一层；在卷积神经网络中，是通过卷积的计算输出，取每个区域进行处理，连接到输出中的神经元。

2. 在传统神经网络中，通过调整权重，完成由输入到输出的过程；在卷积神经网络中，是通过改变卷积核，得到输出。

从数学角度来说，卷积是指用来计算一个函数和另一个函数有多少“重叠”的部分。设想有一条高且窄的正态形状曲线和一条较矮且宽的正态形状曲线，那么两个曲线沿  $x$  轴各点重叠部分的积的面积（即函数积分），就是两个函数的卷积。以下图为例：

图 17：函数的卷积图示

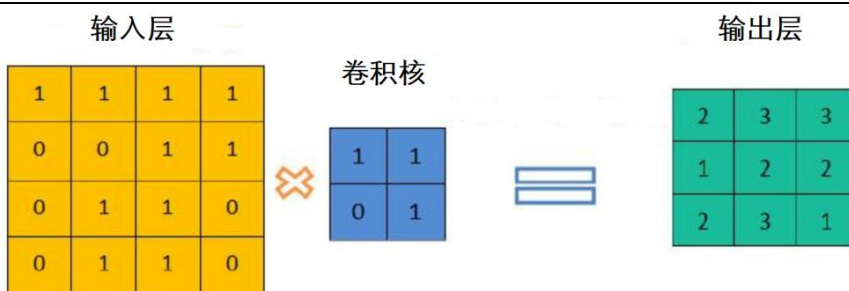


资料来源：长江证券研究所

图中绿色的函数为  $f$  和  $g$  的卷积，蓝色区域代表了  $g(\tau)f(t-\tau)$  的函数值，其面积即为  $x$  取  $t$  时候的两个函数的卷积。

以二维矩阵为例，卷积的过程可以表现如下：

图 18：矩阵卷积过程

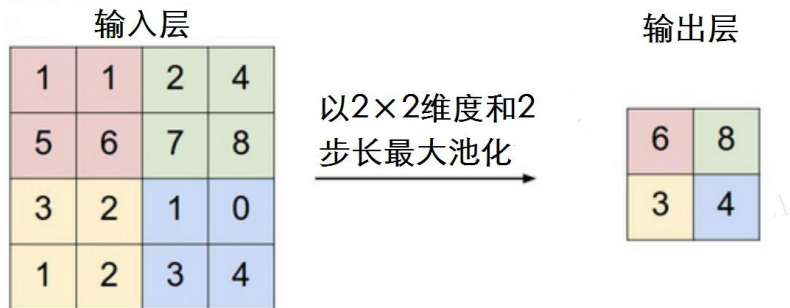


资料来源：长江证券研究所

一般卷积神经网络在经过卷积后，都会再做一层池化的操作。卷积和池化从本质上来说，都是针对图像问题的高维度数据进行降维的过程，在实际操作中，池化也被经验证明为一种降维非常有效的方法。目前最常用的池化为最大池化，其逻辑在于只取图像一个片块的最大值，放弃其他的信息，如图：



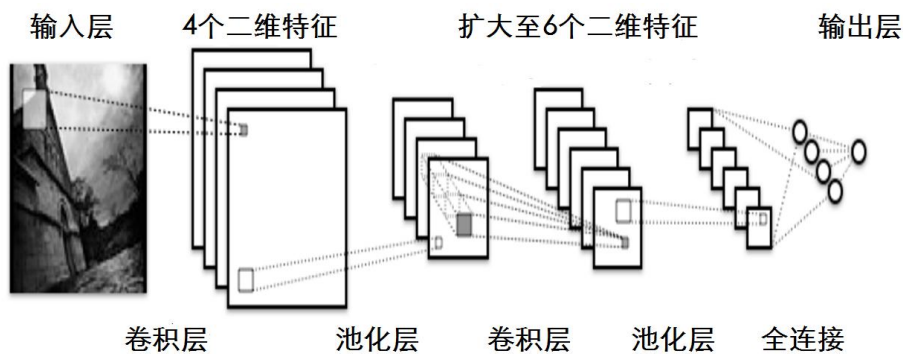
图 19：矩阵池化过程



资料来源：长江证券研究所

经过卷积和池化处理的数据维数大大降低，就可以通过正常的神经网络的全连接层，到最后的输出层。完整的卷积神经网络流程图，以图像处理为例，如下：

图 20：卷积神经网络结构图



资料来源：长江证券研究所

该结构由两个卷积层，两个池化层组成，并最后通过一层全连接的隐含层，到输出层。

由于卷积神经网络在图像识别上有着优异的表现，而技术分析往往会利用价格走势图进行趋势的判断，所以在技术分析的自动化实现上，卷积神经网络会有很好的前景。


## 无监督类方法介绍

本篇以限制波尔兹曼机（Restricted Boltzmann Machine，简称 RBM）为代表介绍深度学习领域中无监督学习方法。限制波尔兹曼机是一种既可以做监督学习，又可以做无监督学习的网络结构。

### 限制波尔兹曼机

以深度神经网络为例的深度学习结构从本质上来说都是一个函数，给定了输入得到一个输出，所以结构都可以用输入层、隐含层和输出层来概括，本质区别在于隐含层的表达不同。限制波尔兹曼机只有两层组成：输入层和隐含层，其中隐含层可以像深度神经网络一样，由多个隐含层组成。限制波尔兹曼机在无监督领域的一个用途就是数据的重构，也即隐含特征的提取。这一过程整体看来可以分为两个过程，第一个过程为正向传播的过程，通过现有数据的输入，得到经过隐含层处理的值，如下图所示：


图 21：限制波尔兹曼机正向传播过程



资料来源：长江证券研究所

第二个阶段为反向传播过程，也可以称为重构阶段。第一隐含层的激活值（如果隐含层不止一层的话）成为反向传递中的输入，这些输入值与之前正向传播用同样的权重相乘，得到的结果再与每个可见层的偏差相加，就得到了重构值，也即原始输入的近似值，具体流程如下图：

图 22：限制波尔兹曼机反向传播过程



资料来源：长江证券研究所

可以看出，正向传播和反向传播的本质区别就是传递的方向不同。通过不断的修正偏差值，来得到最终稳定的模型。在正向传递的过程中，限制波尔兹曼机用输入值来预测节点的激活值，输出的是一个概率： $p(x|a;w)$ 。在反向传递时，激活值成为输入，输出对于原始数据的重构值，即概率 $p(a|x;w)$ 。通过上述两种预测值的结合，就可以得到输入  $x$  和激活  $a$  的联合概率分布，即 $p(x,a)$ 。最终限制波尔兹曼机期望达到的结果是估计原始数据的近似值，即输入数据的一种重构，这个过程像是两条概率分布曲线在逐步重合。

限制波尔兹曼机模型的结果可以用来近似数据的特征，通过对权重进行合理的初始化，为下一步监督学习奠定良好的基础，可以运用在因子的提取以及数据的降维上。如多因

子模型因子的提取，将通过限制波尔兹曼机模型处理后重新分配权重的因子作为多因子模型的输入。

## 强化学习介绍

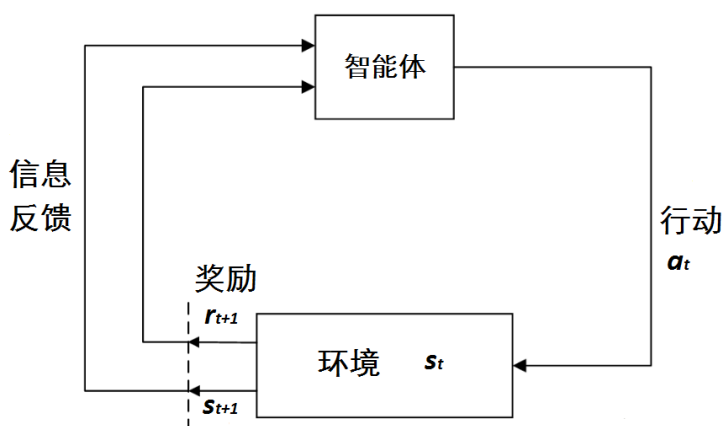
### 强化学习与 Q 学习算法介绍

强化学习 (Reinforcement Learning, 简称 RL) 真正意义上的让机器可以不根据过去已有的数据，而是只根据当前的规则，来学习模型。AlphaGo 就是强化学习的一个成功的案例，下面以围棋对弈这个应用场景来介绍强化学习要解决的问题。在围棋对弈的过程中，我们希望神经网络来预测每一步应该进行的行动，输入一个 19 乘 19 的矩阵，表示当前的棋局状态，输出的是每个点落子的概率，所以如果我们有充分多的棋谱，并假设棋谱的每一步行动都可以有一个明确的状态反馈，即有了每一步的棋局状态 (输入) 和行动之后棋局的情况 (输出)，就可以抽象为一个有监督的任务，进行深度学习模型的训练。AlphaGo 的第一个版本，是根据大量的棋谱，通过蒙特卡洛搜索、深度学习中的监督学习和强化学习的结合，学习到每一步应该进行的行动。而在第二个版本，AlphaGo 彻底进化到不需要棋谱数据，即放弃了深度学习中监督学习的部分，而是由两个电脑不断的对弈，并根据对弈的结果学习模型，即现在不需要之前的数据指导模型应该怎么做，而是根据每次行动的结果给出适当的反馈 (如最终对弈的结果)，这个就是强化学习需要解决的问题。

可以看出，强化学习是位于监督和无监督学习之间的，因为在监督学习中有标签，无监督学习中无标签，而在强化学习中，我们是以一种稀疏且具有延时的标签 (也被称作“奖励”)，来探索在场景中可以获得的最大奖励。

强化学习由环境、行动和反馈三个要素组成，当环境处于某种状态，智能体可以针对当前环境进行某些行动，特定的行动会产生特定的反馈 (如得到奖励)，并产生了新的环境，以此进行下去，直到结束，流程图如下：

图 23：强化学习流程图



资料来源：长江证券研究所

我们将这个过程表示为数学概率论中事件的形式：

$$s_0, a_0, r_1, s_1, a_1, r_2, s_2, \dots, s_{n-1}, a_{n-1}, r_n, s_n$$

其中  $s_t$  表示状态， $a_t$  是动作， $r_{t+1}$  是执行动作后的奖励，并以状态  $s_n$  结束。因为环境随行

动的改变往往是随机的，即以概率的形式改变当前状态，所以可以将状态和行动的集合以及从一个状态到另一个状态的转换规则构成了马尔科夫过程。

强化学习还要考虑长期表现良好的问题，在一个马尔科夫过程中，从  $t$  时刻开始的回报可以表示为：

$$R_t = r_t + r_{t+1} + r_{t+2} + \dots + r_n$$

但是由于环境的改变往往是随机的，对于距离当前时间越远的回报不确定性越强，所以往往会根据时间给回报一个折扣：

$$R_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots + \gamma^{n-t} r_n = r_t + \gamma R_{t+1}$$

$R_t$  也被称为价值函数，用来评估当前环境的好坏，并指导行动。

有很多算法可以用于计算最大化回报，此篇介绍一种最基本的算法—Q-learning (Q 学习) 算法。

Q-learning 中通过定义一个函数  $Q(s, a)$  表示当我们在状态  $s$  执行  $a$  行动后未来奖励的最大值，并从该时间点继续优化：

$$Q(s_t, a_t) = \max R_{t+1}$$

Q 函数表示当前状态下做出的行动可以在结束时获得最大的回报，所以行动的确只需要找到使得 Q 函数最大的  $a$ ：

$$\pi(s) = \operatorname{argmax}_a Q(s, a)$$

这里的  $\pi(s)$  代表了一种策略，也叫环境模型，即每一个状态下根据这个模型选择动作。由前面的介绍我们知道回报在时间上有  $R_t = r_t + \gamma R_{t+1}$ ，同样我们可以用递归关系表示 Q 函数：

$$Q(s_t, a_t) = r_t + \gamma \max_{a_{t+1}} Q(s_{t+1}, a_{t+1})$$

上述式子被称为贝尔曼方程，Q-learning 算法的核心就是用贝尔曼方程迭代逼近 Q 函数，具体流程如下：

1. 初始化  $Q(s, a)$ ；
2. 得到当前状态  $s_t$ ；
3. 做出一个行动  $a_t$ ，并得到当前状态的回报  $r_t$  和下一个时间的状态  $s_{t+1}$ ；
4. 通过贝尔曼方程更新 Q 函数，其中  $\alpha$  为学习率：

$$Q(s_t, a_t) = Q(s_t, a_t) + \alpha (r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t))$$

5. 重复 2-4 步骤直到最后一个状态（即游戏结束，并根据结束状态赋予初值）。

强化学习中除了 Q 学习算法，也常用 SARSA 算法进行价值函数的优化。并且在 Q 学习算法上还有很多改进，尝试与神经网络结构进行结合，来增强模型的准确性。

## 强化学习在金融上的应用场景

金融市场的交易可以看作是一个由当前市场状态作为环境，当前投资行为作为行动，投资的回报作为反馈的过程，强化学习可以用来指导自动化的投资和交易，尤其对于常规

重复性的操作，可以通过自动化交易的方式，减少交易员的工作量。目前 J.P.Morgan 的电子化交易团队就利用强化学习的算法开发了限价订单下单模块（LOPM），旨在最大限度及高效的（数秒到数分钟内）降低滑移，完成任务。通过提供市场规模/价格数据（如差价），执行数据（如填充量），市场信号（如订单流）和模型估计（如波动率预测）等数据给模块，并在明细表（如数量和时间范围），订单（如限价）和市场条件（如最小变动价位）的约束条件下操作，约束也可来自于客户自定义（如客户是风险厌恶型）或自定义的模型参数（如评估频率）。在这些限制下，LOPM 可以自行决定执行积极的（即跨越扩展）还是被动订单（在订单的每个价格水平上分配最佳数量）。

## 总结

深度学习作为一种强大的人工智能技术，已经越来越呈现代替传统机器学习算法的趋势，在金融方面也越来越多的被用来探索新的思路。本文从三个分支——监督、无监督和强化学习，介绍了深度学习的算法、模型的适用范围和金融领域中的潜在应用场景。总结起来，各个算法内容如下表所示：

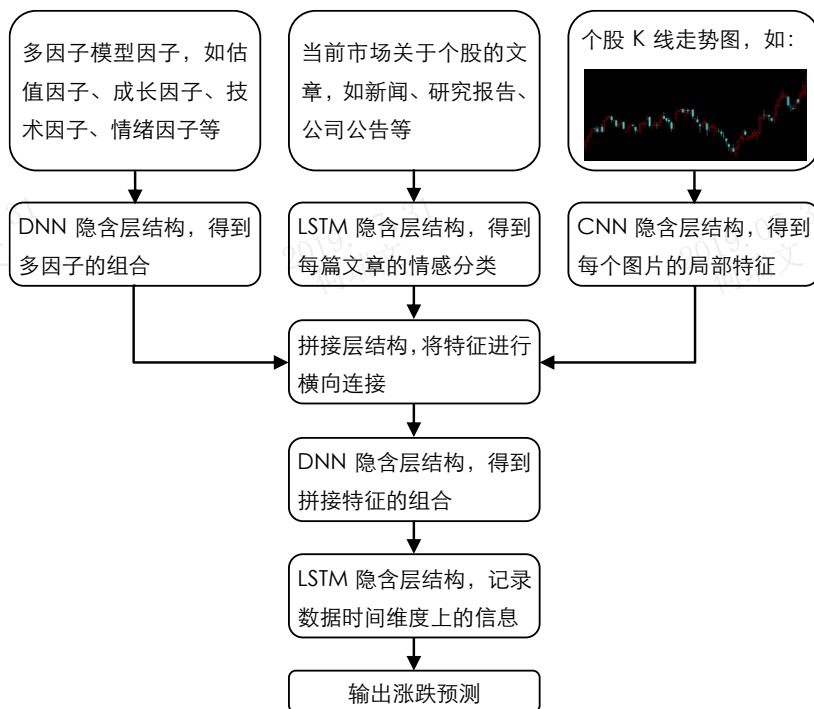
表 9：传统机器学习和深度学习比较

深度学习方法	解决的问题	深度学习算法	金融领域情况
深度神经网络	监督学习	通过多层隐含层的连接，学习输入和输出之间的非线性关系	给定已标签好的输入变量，进行回归或分类的预测
卷积神经网络	图像识别	局部搜索和卷积可以很好的处理高维数据	图像识别指导的投资，如技术分析投资自动化；以间接为主，如通过识别方式搜集基本面数据源用于量化策略
循环神经网络	语音识别	随数据的输入产生动态模型，可以用来处理时间维度上的数据	间接为主，如分析社交媒体中的文本来进行舆情监控和分析
限制波尔兹曼机	拟合数据分布	隐含单元的数目足够多时可以拟合任何的离散分布	数据降维处理，如提取多因子模型的组合因子，影响市场主要因素提取
强化学习	环境到行为映射关系的学习	不需要数据的事先标注	自动化交易的实现，如策略的实盘运作

资料来源：长江证券研究所

很多时候深度学习模型不是单独使用的，深度学习网络可以相互结合，得到更好的效果。我们就预测资产价格方向这一应用场景，给出一种结合多个深度学习算法的选股思路：

图 24：多种深度学习方法结合的选股流程



资料来源：长江证券研究所

流程中我们将传统多因子模型选股、文本情感分类选股和图像识别的技术分析选股三个结合为一个整体的复杂神经网络，并在之后加入若干全连接隐含层和 LSTM 隐含层，最后给出选股的涨跌预测标签。

本文以几种典型的深度学习算法介绍为主，所有实例均是方便具体化各种模型的应用环境，并熟悉模型的操作过程，实际投资中可以结合表 9 中的应用情景做更为深度的延展和探索。



## 投资评级说明

行业评级	报告发布日后的 12 个月内行业股票指数的涨跌幅度相对同期沪深 300 指数的涨跌幅为基准，投资建议的评级标准为：
看好	相对表现优于市场
中性	相对表现与市场持平
看淡	相对表现弱于市场
公司评级	报告发布日后的 12 个月内公司的涨跌幅度相对同期沪深 300 指数的涨跌幅为基准，投资建议的评级标准为：
买入	相对大盘涨幅大于 10%
增持	相对大盘涨幅在 5%~10%之间
中性	相对大盘涨幅在-5%~5%之间
减持	相对大盘涨幅小于-5%
无投资评级	由于我们无法获取必要的资料，或者公司面临无法预见结果的重大不确定性事件，或者其他原因，致使我们无法给出明确的投资评级。

## 联系我们

### 上海

浦东新区世纪大道 1198 号世纪汇广场一座 29 层 (200122)

### 武汉

武汉市新华路特 8 号长江证券大厦 11 楼 (430015)

### 北京

西城区金融街 33 号通泰大厦 15 层 (100032)

### 深圳

深圳市福田区福华一路 6 号免税商务大厦 18 楼 (518000)

## 重要声明

长江证券股份有限公司具有证券投资咨询业务资格，经营证券业务许可证编号：10060000。

本报告的作者是基于独立、客观、公正和审慎的原则制作本研究报告。本报告的信息均来源于公开资料，本公司对这些信息的准确性和完整性不作任何保证，也不保证所包含信息和建议不发生任何变更。本公司已力求报告内容的客观、公正，但文中的观点、结论和建议仅供参考，不包含作者对证券价格涨跌或市场走势的确定性判断。报告中的信息或意见并不构成所述证券的买卖出价或征价，投资者据此做出的任何投资决策与本公司和作者无关。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌，过往表现不应作为日后的表现依据；在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告；本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本公司及作者在自身所知范围内，与本报告中所评价或推荐的证券不存在法律法规要求披露或采取限制、静默措施的利益冲突。

本报告版权仅仅为本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制和发布。如引用须注明出处为长江证券研究所，且不得对本报告进行有悖原意的引用、删节和修改。刊载或者转发本证券研究报告或者摘要的，应当注明本报告的发布人和发布日期，提示使用证券研究报告的风险。未经授权刊载或者转发本报告的，本公司将保留向其追究法律责任的权利。